多终端任务调度系统场景设计方案

作品名称：多终端任务调度系统

赛道：场景设计。场景类型：面向实际需求的应用场景设计方案。版本：2.4.1-slot-aware；材料更新日期：2026年11月12日。实测采集日期保留为2026年11月11日。

本方案提出办公空间内多台设备协同处理巡检事件的应用设计，并提供可运行原型、对比实验与进一步验证路径。目前已完成应用层协同软件、真实双机CPU业务算法测试、同机演示和参数化仿真。最新依据为results/slot_aware_20261111_report.txt及同名summary.json；A四槽/B四槽，450项正式任务与54项预热全部一次执行完成。场景需求仍是设计假设，尚无用户访谈或外部业务试点证据。执行完成不等于结果正确性验收，压缩输出跨机差异仍未解决。项目以任务分配和完成时限保障为研究重点，实际部署价值仍需实地检验。

一 场景概述

背景与业务需求来源

小型办公空间可能同时使用笔记本、台式机和边缘设备，处理来自人工巡检、门禁或环境监测系统的事件。不同设备忙闲不一，而业务任务具有不同处理时限。如果所有任务固定交给某一台电脑，集中到达时可能排队；如果把任务随意送给其他设备，又可能受到网络开销、处理能力和数据范围约束的影响。

本项目拟服务承担办公室巡检的管理人员与负责设备维护的技术人员。前者需要及时得到可复核的事件分类结果，后者需要判断任务为何分配到某台设备、等待发生在哪里、节点掉线后任务如何恢复。现阶段这些需求是待验证的业务假设。团队已说明有办公室可用，但没有已完成的访谈或用户证明。后续将采用半结构访谈和任务观察，核查事件频率、可接受时限与现有处理流程；若任务本身稀少或单机足够，接受“不需要多机”的结论并收缩应用范围。

场景摘要

参见同目录《作品简介.txt》，为报名系统准备的300至500字简介。核心过程为：提交巡检文本或日志分析、文档检索、脱敏压缩任务规格及完成时限，协调器筛选允许处理数据的在线节点，再根据逐槽等待、通信和分类型计算成本选择执行端。Qwen在A提出分配方案，经排程保护校验后派发；执行端返回结果与耗时，协调器保存全过程。观察者可以比较不同策略下的按时完成率和尾部时延，而不是只看演示动画。

当前实现形态

原型由网页工作台、协调服务、独立执行进程和实验脚本组成。核心Python服务与规则模式仅依赖标准库；AI调度模式另需A已有的Qwen3.5-9B Q6_K量化模型与支持该模型的llama.cpp服务，交付包不含模型权重或模型运行时。Qwen只做节点分配，不做业务分类，B无需安装模型。执行端支持日志解析统计、TF-IDF式文档检索与脱敏后zlib压缩，输入为固定种子合成业务数据，实际执行CPU算法；没有用人工循环冒充这些业务计算。原有48条合成样本训练的朴素贝叶斯分类器仍作为巡检文本演示保留，分数未校准且需人工复核；尚无真实消防识别或视频巡检能力。

二 场景需求分析

业务痛点与现有方案

固定单节点部署容易管理，在事件少、单机负荷低时往往足够。轮询分配易于实现，但没有利用设备服务速度与通信条件。随机分配可作为粗基线，却可能把紧急任务送入较长队列。将任务全部发送远端计算也不必然更快，传输与往返开销可能抵消计算优势。以上为待验证的机制分析，不是对所有既有产品的性能结论。

Ray已提供资源感知、数据局部性及多种调度机制，KubeEdge提供基于Kubernetes的云边应用编排与设备管理。因此，本项目不把“多机接入”“节点心跳”或“故障重试”当作首次提出的技术。本项目的差异在于面向小型办公场景，把完成时限、通信代价与管理员设定的数据范围放在一个容易理解和复现的工作流中。与成熟框架相比，本原型功能、规模、安全隔离与生产可靠性均有明显局限，尚未进行框架间性能对比。[4][5]

需求指标与验收口径

指标	计算方式	现阶段状态	下一步验收
按时完成率	截止前返回结果的任务数除以全部提交任务数	已有双机实测，按版本与轮次分别报告	多机每策略至少5轮，不剔除失败任务
端到端时延	协调端收到结果减去收到提交的时间	双机记录使用同一协调端时钟	报告均值与P95，注明负载
尾部时延	每轮任务时延的最近秩P95	仿真与实际记录分别计算	独立报告超时和失败
通信载荷	JSON任务载荷字节乘以派发尝试次数	仅应用载荷估计	后续抓包测总流量
恢复能力	租约到期重排及旧结果拒收	自动检查覆盖	实机断开执行端并录屏
事件分类质量	独立标注集上的宏平均F1与漏报率	尚无真实数据指标	至少100条去标识事件，单独评测

预期目标为：在排队或网络瓶颈确实存在时，联合调度相对固定分配提高按时完成比例；在负载很低时保持可解释且可接受的额外开销。这是验证目标，不承诺固定提升百分比。完成率改善需用百分点与相对比例分别表达，并给出对照策略和条件。

三 场景方案设计

总体架构与业务流程

工作台通过HTTP接口提交任务及范围、时限配置。协调服务保存任务、节点与事件记录，执行调度和租约管理。执行节点主动注册，周期上报心跳并轮询任务，执行所支持的CPU业务算法或轻量分类后返回结果。SQLite保存在协调端本地，记录可导出为CSV。系统不执行用户上传的任意代码，也不从远端下载模型。

一项任务按“排队、运行、完成”推进；可取消，也可在异常时重排或标为失败。每次派发生成独立租约，心跳仅在节点报告仍处理对应任务且租约匹配时延长有效期。默认每2秒心跳、10秒未更新视为离线、25秒租约到期后重排，最多尝试3次。协调器重启将运行中的任务重新入队，使旧节点结果失效。任务可能被重复计算，但只有匹配当前租约的结果可以提交，因此不宣称端到端恰好一次执行。

联合调度机制

排队任务按绝对截止时间排序。对每项任务，先去除离线、暂停接收或不满足数据范围的节点。可信范围由管理员设置；“仅可信节点”不意味着仅协调端本机，也不意味着硬件可信执行证明。远程节点默认不可信，需经人工核实后配置。

对于每个可选节点，预测完成耗时为：预计剩余等待时间，加HTTP往返耗时，加任务字节乘8除以配置带宽，再加1.15倍的计算耗时预测。计算耗时按节点和业务类型分别校准；旧分类演示仍按文本条数与人工负载单位估计。单位耗时在完成后以0.65旧值加0.35新样本进行EWMA更新。1.15为固定余量，不是经过验证的置信区间。

评分为预测耗时加上两倍的预计超时惩罚，选择最低分节点。该惩罚函数对预测耗时单调递增，因此在同一任务下与最小预测完成耗时排序一致。时限的实际作用主要体现在任务队列采用截止时间优先，以及结果是否按时完成的评价。本项目不把这个简单启发式包装成具有最优性证明的新算法。节点轮询和预测误差会影响实际效果，需要进一步实验。

当前另有Qwen辅助调度路径：A上的模型读取独立任务成本、逐槽可用时间、配置和负载，最多一批8项；整批重放模型建议，与规则基础上最多两轮优化重排的保护参考比较。未开始的任务可改派到更早完成的空闲节点。最终来源分别记录qwen（原样建议）、qwen_guarded（采用保护方案）和rules_fallback（模型异常或等待超限回退）；qwen_guarded不代表批内每项都改变节点。重任务排程等待最多8秒、短任务4秒、单次模型请求3秒，等待计入端到端耗时。保护收益不能全部归因于模型。

固定单节点、轮询和随机策略作为基线，共享相同的可信范围过滤。双机业务性能对照使用A单机、B单机、双机规则和Qwen路径；旧仿真四策略不含Qwen。固定策略未指定节点时选择ID排序最前的合格节点；轮询与随机选择在等待节点领取时保留，避免因轮询频率变化而重抽样。实际系统按可用状态派发，仿真则在到达时计算节点队列，两者不是完全同构的执行时序，应分别报告。

AI与6G的结合

ITU-R M.2160提出IMT-2030发展框架，其中包含AI与通信融合的应用方向。多终端任务调度系统围绕分布式设备处理AI任务时的通信与计算关系设计应用流程，研究“哪里处理、何时完成、哪些节点可以处理”三个问题。[3]

当前实现使用普通HTTP网络，与无线接入技术解耦；可在既有以太网或Wi-Fi环境进行应用验证。它没有6G基站、空口、原生网络智能或标准协议栈接入。未来若可获取更准确的网络遥测、资源描述和服务质量保障，可将这些信息接入预测与筛选逻辑，但这属于接口演进设想。不能用现有仿真结果证明6G网络性能或宣称已经符合尚未验证的标准接口。

资源协同与部署

协调端部署在办公室管理电脑，执行端部署在团队有权限使用的其他电脑。当前双机配置为A四槽/B四槽，实际并发峰值均达到4；槽数由执行端启动参数控制。节点上报CPU型号、核心数、CPU使用率、内存及可检测的GPU信息，未上报或过期值不能当作实时真值。业务任务使用CPU，GPU展示不等于任务使用GPU；槽占用比例不是CPU利用率。未测量温度与电量。HTTP往返耗时是最近一次软件请求的观察值，带宽为配置参数。系统不自动发现局域网设备，需显式启动执行端。

软件可运行于Python 3.10及以上环境。Windows提供一键脚本，其他系统可直接使用命令行。界面无需网络字体或CDN。原型限制最多保存64个节点和20000项任务，界面显示最近200项；它不是大型集群压力测试的规模结论。

数据与安全

默认协调端仅绑定127.0.0.1，LAN模式需显式启用。接口使用随机接入令牌，浏览器会话采用HttpOnly与SameSite严格Cookie，修改接口校验Origin。CSV导出处理潜在公式前缀，动态文本进行HTML转义。没有令牌的请求不能读取任务内容。

原型使用共享管理令牌，未实现细粒度角色、按节点独立凭证、TLS与自动密钥轮换。LAN HTTP没有传输加密，令牌、事件文本和数据库必须限定在团队自己的可信实验环境内。共享令牌持有者能够管理节点与任务，因此不能作为不可信多租户平台部署。

四 技术落地性

成熟度与依赖条件

目前成熟度为内部研究原型。可以在本机启动协调器与两个真实执行进程，提交文本并观察分类、调度与持久化结果。最新报告记录57项回归通过，已取得真实双机任务与并发记录；这些证据不能替代真实办公需求、业务结果质量或模型泛化能力的验证。

两名成员分别有软件工程与电子信息工程背景，团队已说明有办公室可用。除此之外，未声称具有外部合作单位、行业客户或专利成果。硬件优先使用已有两至三台电脑，暂不采购开发板、无人机或专用6G设备；只有验证出现真实瓶颈后再补充硬件。

已完成的双机实测

2026年11月11日优化测试共450项正式任务、54项预热，全部一次执行完成；该总量跨2.3.0参考、2.4.0优化及2.4.1专项复测，不能称为450项均由2.4.1完成。2.4.0标准与混合任务各三轮，持续吞吐一轮；2.4.1对标准、混合与持续吞吐各补一轮AI专项复测。

24项持续重任务的2.4.1最终复测为58.278秒，24/24完成且按时，6项qwen、18项qwen_guarded，无规则回退；其中12项最终节点相对模型建议改变。前轮同输入规格的参考为A单机101.644秒、B单机87.646秒、双机规则51.559秒；这是跨轮参考，非同轮同时测量，规则仍更快。2.4.0持续队列中16项规则回退保留在原始记录，不以专项复测覆盖。

日志与检索结果跨机一致，压缩输出跨机差异仍待核查，整体正确性验收未通过。输入是合成规格，两机独立生成数据；网络只传紧凑描述，不代表完整业务文件传输。背景负载、温度与供电未控制，在线校准未重置；持续吞吐仅一轮，不作显著性或泛化结论。详细指标、轮次和原始记录见测试报告及release-evidence目录。

历史参数化验证（非Qwen实测）

实验设置三种假设条件：正常网络、受限带宽和任务突发。节点由三个配置档描述，其中一个标为假设云端，不代表实际购买或接入了云服务。正常配置分别为每单位32/65/12毫秒、RTT为3/9/80毫秒、带宽为80/40/25Mbps；受限带宽配置改为RTT 15/25/180毫秒和带宽8/4/1Mbps。任务突发条件缩短平均到达间隔，其余与正常配置一致。

每条件运行30个种子、每次240项任务、每项策略使用相同输入与作业噪声，共86,400条记录。四分之一左右的任务受可信节点限制，各策略使用相同规则。任务时限来自250、500、1000和2000毫秒的合成配置，载荷从4KB、32KB和256KB中选取。原型实际发送小文本，大载荷仅用于网络敏感性分析，不声称真实文本业务具有该数据量。

各策略使用同一负载序列。区间按每个种子的指标计算近似95%均值区间，避免将同一轮内相关任务视为全部独立样本。逐任务、逐种子数据与输入哈希均保存。自动生成的结果表附于测试报告与答辩材料。

需要注意，仿真调度器准确获知名义服务时间与队列，没有模拟丢包、设备故障、信道竞争、模型冷启动或GPU显存。因此其收益可能高于真实部署。特别是固定节点接近或超过承载能力时，对比差距会被放大，不能外推至任意负载，也不能据此说明本方案一定优于成熟系统。仿真中不同条件下的时延、完成率需同时查看，不能只挑选最大提升展示。

后续现场与质量验证计划

选择两至三台物理电脑，记录CPU型号、内存、系统、网络连接方式、模型版本与后台负载。在同一任务文件下依次测试四种策略，每种至少5轮，每轮至少100项。先进行预热，再保存任务原始CSV与全量结果；基线顺序随机化或轮换，避免背景负载随时间变化造成系统偏差。

测试至少包含低负载、突发提交、快节点被占用和执行端断连四类条件。丢失或失败任务必须保留，不能只统计成功样本。单独比较真实分类耗时与人为负载循环；真实模型计算足够快时，明确指出多机通信可能使完成时间变差。成本比较计入维护、能耗与部署时间，不只比较设备采购价。

实际场景补充不少于3位潜在使用者访谈，记录目前流程、事件频率、时限和可接受误报。经同意采集不少于100条去标识事件，训练与测试按来源或时间划分，避免模板重复泄漏。没有用户同意时只用合成数据，不录入个人身份、门禁凭证或敏感区域信息。真实双机软件测试已完成；访谈、真实业务输入评估及外部试点仍待执行，继续补充设备与环境记录。

实施里程碑

2026年10月26日形成原型与材料初稿，10月27日统一对外名称。11月11日已形成双机业务与逐槽优化报告。11月12日按2.4.1统一方案、测试、讲稿及AI资源声明，历史数据不改采集日期。后续优先核查压缩输出差异、补需求访谈与真实业务质量证据；旧计划中的日期不等于这些事项已完成。赛事时间与上传要求沿用10月26日通知记录，实际提交前按报名系统核对。[1]

五 产业价值与推广

可量化的应用效果

项目期望减少在突发任务下的超时比例，提高已有设备处理资源的可见性，并提供易于定位排队问题的记录。当前没有客户部署前后数据，不把仿真比例写成真实生产效率提升。实际价值需要同时成立：任务量足以造成瓶颈；其他节点确有可用计算资源；网络和管理开销低于分担收益；结果质量不因模型部署差异而改变。

对于任务少、设备集中或数据禁止离开本机的环境，固定单机可能更合适。当前调度器支持约束，但不自动证明数据合规。推广前必须明确组织授权、数据生命周期和运行维护责任。

复制条件与经济效益

适合首先验证的对象是有少量闲置电脑、存在周期性事件处理任务的小型办公空间或实验室。复制需要可安装Python的设备、可信网络、可描述的任务时限以及一个负责协调服务的人。更重的视觉或语言模型需新增依赖、模型许可、资源描述、冷启动与准确率验证，不是改一个标签即可完成适配。

预算采用“已有电脑复用优先”的资源方案，不给出未经询价的市场价格。成本分析记录新增硬件实际凭证、部署与维护工时、电费和许可证费用。项目暂不提供市场规模、收入预测、签约客户或专利价值等未经验证数字。若现场验证表明收益不足，则把成果定位为教学与实验工具，而非强行推断商业成立。

推广风险

主要风险为需求不够强、模型效果不稳定、预测误差造成调度波动、协调端单点故障、共享令牌泄漏和测试样本不足。当前通过缩小场景、人工复核、租约重试、数据持久化及原始记录降低部分风险；高可用协调、加密网络、独立身份与资源隔离尚未实现。对这些限制的解决将决定其能否进入真实业务。

六 团队与保障

软件工程成员负责协调服务、工作台、接口与执行进程，维护复现脚本和代码版本。电子信息工程成员负责物理组网、节点配置、网络指标口径、断连试验与实验记录。两人共同完成业务访谈、模型误差复核、材料审核和答辩演练。公开材料使用专业分工描述，不出现所在单位或指导教师信息。

每天约1小时投入时，按“5分钟对齐、40分钟单项工作、15分钟复核”组织；以当天形成的文件、原始数据或录像作为进度依据。预算与场地由团队实际情况确认，尚未形成外部资金、数据授权或合作证明时不写入已取得资源。

七 附录与资料来源

自动测试报告、仿真明细、本机流程记录、真实双机原始任务与资源采样、系统截图和运行命令构成当前佐证。真实用户证明、办公室照片、第三方合作或知识产权证明须在取得后另附，当前不提供虚构附件。

生成式AI使用说明见独立文件。方案文字、代码、实验、材料与结果解释由AI辅助制作，最终由两名成员逐项核查并承担责任。Qwen及llama.cpp用于可选AI调度运行路径，Python标准库用于核心服务，另有工具用于材料构建；项目运行不含Ray或KubeEdge依赖。模型来源、许可核对与尚缺的量化文件追溯信息见《AI使用与第三方声明》。

[1] 组委会 首届人工智能+6G青年创新创业专项赛通知及附件入口。https://www.aicomp.cn/tracks/tracks-4/5322.html 。核对日期2026-10-26。

[2] 组委会 同页附件1作品提交要求及附件2作品方案大纲与评分标准。依据其场景设计章节组织本方案，正式上传前再次核对报名系统。

[3] ITU-R M.2160-0 Framework and overall objectives of the future development of IMT for 2030 and beyond。https://www.itu.int/rec/R-REC-M.2160-0-202311-I/en 。核对日期2026-10-26。

[4] Ray官方文档 Scheduling。https://docs.ray.io/en/latest/ray-core/scheduling/index.html 。仅作为已有技术能力参考，未进行对照产品性能实验。核对日期2026-10-26。

[5] KubeEdge官方文档 Why KubeEdge。https://kubeedge.io/docs/ 。仅作为云边编排参考，未进行对照产品性能实验。核对日期2026-10-26。